

多臂赌博机

第1章 多臂赌博机问题 (Multi-armed Bandits)

1.1 问题描述

多臂赌博机问题 (Multi-armed Bandits, MAB) 是一个经典的强化学习问题。该问题可以描述如下:

假设存在 k 个独立的老虎机 (赌博机), 每个摇臂摇动后以固定但未知的概率 p_i ($i=1,2,3,\dots,k$) 获得一个硬币 (收益为 1), 以概率 $1-p_i$ 不获得硬币 (收益为 0), 在摇动 n 次后, 如何最大化总收益 R 。

1.2 问题抽象

1.2.1 动作

原问题中的摇臂摇动可以抽象为一个动作, k 个不同老虎机的摇臂摇动就可以认为是 k 种不同的动作, 记动作集合为 $A = \{a_1, a_2, \dots, a_k\}$, 不同的动作会产生不同的回报。

1.2.2 动作价值

考虑到每个动作的收益并不一定是一个二项分布, 所以认为每个动作 $a \in A$ 的收益 R_i ($i=1,2,3,\dots,k$) 关联一个未知的概率分布 ν_a , 并认为该分布满足平稳概率分布 (随机过程的统计特性如数学期望和方差等不随时间的推移而变化)。

将动作 a_i 对应的期望/平均收益称为动作 a_i 的**价值**, 记作 $q_*(a_i)$ 。

$$q_*(a_i) = \mathbb{E}[R_i | a_i]. \quad (1)$$

1.2.3 时间步

假设存在离散时间步 $t=1,2,\dots,T$ (T 可以有限也可以无限), 每个时间步进行一个动作, 对应 n 次摇动摇臂, 将在时刻 t 进行的动作记作 A_t , 获得收益 R_t ($t=1,2,3,\dots,T$) 对应的动作价值为 $q_*(A_t)$ 。(注意区别 A_t 和 a_i)。

则在时刻 t 进行动作 A_t , 对应的动作价值为:

$$q_*(A_t) = q_*(a_i) = \mathbb{E}[R_t | A_t = a_i]. \quad (2)$$

1.2.4 抽象后的问题

在每个时间步 t 时选择一个动作 $A_t \in A$ ，获得收益 R_t ，在 T 个时间步里如何最大化累积的收益 $\sum_{t=1}^T R_t$ 。

1.3 基础解决方法

k 个动作存在 k 个价值 $q_*(a_i)$ ($i=1,2,3,\dots,k$)，对于价值知道与否，存在两种情况：

1.3.1 每个动作的价值已知

想要最大化收益，可以认为需要最大化收益的期望。在已知动作价值的情况下， T 个时间步的选择都选价值 $q_*(a_i)$ 最大的动作即可实现最大化总收益。

1.3.2 每个动作的价值未知

当动作的价值未知时，我们需要对动作的价值进行估计，**动作-价值方法**是一种常用的方法，这种方法通过期望的估计值选择动作，又通过动作后的收益更新估计值。

1.3.2.1 动作价值的估计

可以通过计算实际收益的平均值来估计动作的价值，将：

$$Q_t(a_i) \doteq \frac{t \text{时刻前通过执行动作} a \text{得到的收益总和}}{t \text{时刻前执行动作} a \text{的次数}}. \quad (3)$$

当分母为 0 时，将 $Q_t(a)$ 定义为某个默认值，这种方式叫做**采样平均方法**。

1.3.2.2 贪心算法

在对每个动作价值的估计中，在每一个时刻 t 都存在动作的估计价值是最高或并列最高的，称之为**贪心**的动作。

在每一个时刻 t 都选择贪心动作，存在多个贪心动作时随机选择一个，方法如(4)所示：

$$A_t \doteq \operatorname{argmax}_a Q_t(a), \quad (4)$$

其中， argmax_a 是使 $Q_t(a)$ 值最大的动作 a 。

第2章 贪心算法的分析实现与改进

2.1 测试平台